

Трек «Искусственный интеллект» — Красный уровень

Объяснитель: выравнивание языковой модели

Знакомая ситуация: спрашиваешь нейросеть о чём-то сложном (про чёрные дыры, про инфляцию и тд) и получаешь безупречно научный текст, который без подготовки не разобрать. Можно каждый раз добавлять «объясни проще», но это ручная работа на каждый запрос, и стоит её забыть, как снова возникает стена терминологии.

Гораздо надёжнее, когда нужное поведение зашито в саму модель, а не в промпт. Промпт задаёт его разово и хрупко; дообучение делает его свойством модели. В этой задаче ты не подсказываешь модели, как себя вести, а меняешь её саму.

Перед тобой полный цикл, которым в AI-лабораториях выравнивают (alignment) языковые модели под человека: дообучение на примерах (SFT), обучение модели-оценщика качества (Reward Model), оптимизация по предпочтениям (DPO и SimPO). Пять шагов. На каждом важно не просто запустить обучение, а понимать, что именно меняется в модели, и подтверждать это измеримой метрикой.

Результат — компактная модель (обучается в Colab или Kaggle), которая по умолчанию, без специальных промптов, объясняет просто, с аналогиями и без потери смысла.

Как выглядят данные

`kid_adult.jsonl` — ось стиля: один и тот же ответ в простом и сложном регистре.

`good_bad.jsonl` — ось качества: оба ответа в простом стиле, но один лучше другого по сути.

Различие между датасетами принципиально: воспроизвести стиль легко, а сохранить при этом фактическую точность трудно. На этом контрасте построена вся задача.

Что тебе дано

Модель

Qwen/Qwen3-4B-Instruct-2507
(Hugging Face, именно эта

	ревизия — не Base, не Thinking), обучается в Colab или Kaggle T4 через QLoRA (4-bit)
Данные	kid_adult.jsonl, good_bad.jsonl (обучение); public_test_style.jsonl, public_test_quality.jsonl (самопроверка)
Измерители	style_clf.pkl — оценка простоты ответа (P_simple); gold_rm/ — модель-судья качества
Правила	зафиксируй seed = 42, генерация greedy (do_sample=false). Ответ на каждую задачу — буква интервала (А/Б/В/Г), в который попала метрика.

Главное требование. Вместе с ответами сдаётся **ссылка на git-репозиторий** (GitHub/GitLab) с Colab-ноутбуком, и ноутбук должен быть полностью воспроизводимым: - запускается сверху вниз без ручных правок и доходит до конца; - все random seeds зафиксированы (seed = 42); - присутствуют ячейки, которые вычисляют и печатают каждую из пяти метрик — те самые значения, по которым выбраны интервалы; - модель и адаптеры обучаются внутри ноутбука, а не подгружаются готовыми извне.

Требования к репозиторию: - ноутбук коммитится в репозиторий **по ходу работы** (несколько коммитов по мере продвижения по задачам, а не один финальный залив); - история коммитов должна согласовываться со сроками тура — репозиторий, созданный целиком после дедлайна или заполненный одним коммитом в последнюю минуту чужой готовой работой, ведёт к **дисквалификации**; - переписывать историю (force-push, изменение дат коммитов) нельзя — это проверяется.

При проверке ноутбук перезапускается. Если он не воспроизводит заявленные значения, какая-либо метрика отсутствует или числа не подтверждаются, баллы за соответствующую задачу обнуляются. Воспроизводимость результата — обязательная часть инженерной работы.

Конкретные гиперпараметры не даются: их подбор есть часть задачи. При корректно пройденном пути и понимании различия стиля и смысла значения метрик выходят на нужный уровень закономерно.

Какие данные для какой задачи

Задача

- 1 — SFT
- 2 — DPO по стилю
- 3 — Reward Model
- 4 — DPO по качеству
- 5 — SimPO

kid_adult и good_bad — обучающие наборы. Файлы public_test_* отложенные, только для подсчёта метрик, не для обучения.

Задача 1 — SFT: перенос стиля

Базовая модель по умолчанию отвечает в сложном регистре. Дообучение на примерах простых объяснений переносит нужный стиль: после этого шага модель начинает объяснять проще без дополнительных инструкций.

Действие: дообучи (SFT) базовую модель на kid_adult. **Метрика:** средний P_simple ответов на public_test_style (seed=42, greedy). **Ответ — выбери интервал, в который попал P_simple: А) < 0.4 Б) 0.4 - 0.7 В) 0.7 - 0.9 Г) 0.9 - 1.0**

Задача 2 — DPO по стилю: закрепление предпочтения

SFT задаёт стиль, DPO закрепляет предпочтение. На парах «простой и сложный ответ» модель учится последовательно выбирать простой регистр.

Действие: поверх SFT прогони DPO на kid_adult (chosen — простой, rejected — сложный). **Метрика:** P_simple на public_test_style (ожидается рост относительно Задачи 1). **Ответ — выбери интервал P_simple: А) < 0.4 Б) 0.4 - 0.7 В) 0.7 - 0.9 Г) 0.9 - 1.0**

Задача 3 — Reward Model: модель-оценщик качества

Чтобы улучшать качество, а не только стиль, нужен оценщик: модель, отличающая хорошее простое объяснение от плохого. Это ядро RLHF, качество reward-модели задаёт потолок всего выравнивания. Типичная ошибка — обучить оценщика на поверхностных признаках (тон, форма), а не на сути.

Действие: обучи reward-модель на good_bad (хороший ответ предпочтительнее плохого). **Метрика:** pairwise accuracy на public_test_quality — доля пар, где судья оценивает хороший ответ

выше плохого. **Ответ — выбери интервал accuracy: А) < 0.6 Б) $0.6 - 0.75$ В) $0.75 - 0.9$ Г) $0.9 - 1.0$**

Задача 4 — DPO по качеству

Стиль закреплён, теперь оптимизируется содержание. На парах «лучше и хуже» (оба в простом стиле) модель учится отвечать точнее, не подменяя смысл правдоподобной ошибкой (как с астероидом у Юпитера).

Действие: прогони DPO на good_bad (chosen — хороший, rejected — плохой). **Метрика:** implicit-preference accuracy на public_test_quality — доля пар, где модель присваивает хорошему ответу больший **средний logprob на токен ответа** (сумма logprob токенов ответа, делённая на их количество — length-normalized), чем плохому. Без генерации, детерминированно. Нормировка на длину обязательна: сырая сумма logprob систематически завышает короткие ответы, и метрика перестаёт измерять качество. **Ответ — выбери интервал accuracy: А) < 0.6 Б) $0.6 - 0.75$ В) $0.75 - 0.9$ Г) $0.9 - 1.0$**

Задача 5 — SimPO: сравнение методов

Та же цель, повышение качества, достигается альтернативным методом: SimPO выполняет выравнивание без отдельной reference-модели (экономия памяти). Выполни SimPO и сравни результат с Задачей 4: один и тот же датасет, разные алгоритмы — сопоставим ли итог, и что это говорит о цене reference-модели?

Действие: прогони SimPO на good_bad. **Метрика:** implicit-preference accuracy на public_test_quality (как в Задаче 4, сравни с DPO). **Ответ — выбери интервал accuracy: А) < 0.6 Б) $0.6 - 0.75$ В) $0.75 - 0.9$ Г) $0.9 - 1.0$**

Пройдя все пять задач, ты самостоятельно проводишь компактную модель через полный современный пайплайн выравнивания — тот же, что применяют к большим моделям в исследовательских лабораториях.